

УДК 004.056.5:004.032.26

**ПРИМЕНЕНИЕ МЕТОДОВ ГЛУБОКОГО ОБУЧЕНИЯ ДЛЯ
ВЫЯВЛЕНИЯ ВРЕДОНОСНОГО ПО СРЕДСТВАМИ
СТЕГОАНАЛИЗА**

А.А. Костров

Кубанский государственный университет
ул. Ставропольская 149, 350040, Краснодар, Россия

Ключевые слова: стеганография, стегоанализ, глубокое обучение, свёрточные нейронные сети, вредоносное ПО.

Аннотация. Проблема скрытой передачи вредоносного ПО в изображениях становится всё более актуальной. Традиционные методы стегоанализа недостаточно эффективны против современных алгоритмов встраивания стеговставок. В данной работе предложен подход на основе нейронной сети Yedroudj-Net [3], адаптированной под выявление вредоносных shell-скриптов. Были сформированы датасеты изображений с вирусами. Результаты демонстрируют точность нейросетевого стегоанализа, применяемого для обнаружения вредоносного содержимого.

Введение. Стеганография позволяет скрывать сам факт передачи данных, что делает её эффективным инструментом для маскировки вредоносного ПО в изображениях. Злоумышленники встраивают вредоносные скрипты в легитимные файлы, обходя системы обнаружения. Актуальность работы обусловлена, с одной стороны, успехами глубокого обучения в области стегоанализа, а с другой – отсутствием исследований, оценивающих эффективность нейросетевых распознавателей на реальных образцах вредоносных shell-скриптов. Большинство работ ограничиваются синтетическими шумовыми вставками, оставляя неясным, как архитектуры наподобие Yedroudj-Net справляются с обнаружением исполняемых

скриптов и как специализация на одном алгоритме встраивания влияет на обобщающую способность. Цель работы – реализовать Yedroudj-Net, сформировать датасеты изображений с реальными вредоносными скриптами, встроенными разными стеганографическими методами, и оценить точность обнаружения.

Методология стегоанализа на основе свёрточных нейронных сетей. Классический стегоанализ требует ручного указания признаков и плохо адаптируется к новым алгоритмам встраивания. Глубокое обучение позволяет автоматически извлекать сложные признаки, но требует от модели чувствительности к слабым изменениям значений пикселей. В рамках данной работы была выбрана сеть Yedroudj-Net из-за демонстрации хороших результатов при обучении на относительно небольшом объёме данных и использования предопределённых высокочастотных фильтров.

Архитектура: блок предобработки с 30 фильтрами, извлекающими шумовой остаток; пять свёрточных блоков; полносвязный классификатор с softmax. Особенности: отсутствие коэффициента смещения в свёртке, использование функции усечения и пакетной нормализации. Обучение: SGD с моментом, равным 0,95; размер каждого батча равен 32; затухание весов равно 0,0001; инициализация весов – Xavier [2].

Формирование датасетов изображений со встроенным вредоносным ПО. В качестве исходного набора пустых стегоконтейнеров был взят BOSSBase 1.01 [1] (10 000 изображений размером 256 на 256). В ходе работы сформированы четыре категории датасетов:

- «S-UNIWARD»: стегоконтейнеры, заполненные при помощи алгоритма S-UNIWARD, – был встроен шум с интенсивностями 0,1; 0,2; 0,3; 0,4 и 0,5 bpp – получено по 10 000 изображений для каждого значения;
- «Steghide»: изображения, в которые с помощью утилиты Steghide встроены четыре реальных вредоносных скрипта – Anubis (вымогатель),

AWFULSHRED (деструктивный), DarkRadiation (вымогатель для Linux), IRCbot (бэкдор), – получено по 10 000 изображений на каждый скрипт;

– «Stegano»: стегоизображения, для получения которых применялся Python-модуль Stegano, предоставляющий LSB-метод, – встраивались те же четыре скрипта – получено по 10 000 изображений на каждый скрипт;

– «SHELL»: смешанный датасет – 10 000 изображений, отобранные равномерно из «Steghide» и «Stegano».

Для автоматизации формирования наборов данных были написаны Python-скрипты и MATLAB-программы.

Экспериментальное исследование и результаты. В рамках данной работы были обучены два экземпляра сети архитектуры Yedroudj-Net: первый – на «S-UNIWARD 0,4 bpp», второй – на «SHELL» (в обоих случаях было отведено 4000 пар изображений на обучение, 1000 пар на валидацию и 5000 пар на тестирование: каждая пара состояла из пустого стегоконтейнера и изображения со стеговставкой). Оба экземпляра обучались 400 эпох. Начальное значение шага обучения было равно 0,01; каждые 162 эпохи это число уменьшалось в 10 раз. Тестирование проведено на всех сформированных датасетах (рисунок 1).

<i>Точности на тестовых выборках</i>		
	<i>Yedroudj-Net</i>	
	<i>Обучалась на S-UNIWARD 0,4 bpp</i>	<i>Обучалась на SHELL</i>
S-UNIWARD 0,1 bpp	51,27%	50,38%
S-UNIWARD 0,2 bpp	57,48%	53,37%
S-UNIWARD 0,3 bpp	68,96%	59,28%
S-UNIWARD 0,4 bpp	77,54%	65,81%
S-UNIWARD 0,5 bpp	81,99%	72,25%
Steghide Anubis	64,81%	81,49%
Steghide AWFULSHRED	71,43%	86,54%
Steghide DarkRadiation	79,80%	90,83%
Steghide IRCbot	68,92%	85,49%
Stegano Anubis	55,42%	89,01%
Stegano AWFULSHRED	76,52%	93,31%
Stegano DarkRadiation	78,28%	94,27%
Stegano IRCbot	57,89%	91,63%
SHELL	68,25%	89,31%

Рисунок 1 – Показатели точности Yedroudj-Net на тестовых выборках

Проведённые эксперименты позволяют сформулировать несколько выводов о сильных и слабых сторонах нейросетевого распознавателя стеганографических вставок.

Модель демонстрирует ярко выраженную специализацию: обучение на определённом алгоритме встраивания обеспечивает максимальную эффективность только на нём, причём чем выше интенсивность встраивания, тем лучше результаты. Это свидетельствует о том, что сеть точно подстраивается под уникальные статистические особенности, порождаемые конкретным методом. Однако данная специализация становится причиной низкой точности обнаружения стеговставок при работе с другими алгоритмами.

Модели, которые были обучены на разных алгоритмах, различаются по способности к обобщению. Экземпляр, обученный на «S-UNIWARD 0,4 bprp», показал относительно средние результаты на незнакомых алгоритмах, подтвердив свою узкую специализацию – он настроен на выявление тонких искажений, свойственных адаптивным методам. Напротив, модель, обученная на смешанном датасете «SHELL», оказалась более универсальной и достигла высокой точности, особенно на LSB-методе. Это показывает, что обучение на нескольких разных алгоритмах позволяет сети улавливать более фундаментальные статистические аномалии, являющиеся общими для многих способов встраивания.

Результаты подтверждают классическую закономерность: чем меньше количество скрытых данных, тем труднее их обнаружить. При низкой интенсивности встраивания точность распознавания может падать практически до уровня случайного угадывания. Следовательно, встраивание малых объёмов стеговставок является надёжным способом противодействия стегоанализу.

Заключение. В рамках данной работы был реализован и исследован подход к обнаружению вредоносного ПО, встроенного в изображения, на

основе свёрточной нейронной сети Yedroudj-Net. Впервые эта архитектура применена для обнаружения реальных вредоносных shell-скриптов, встроенных при помощи Steghide, Stegano и S-UNIWARD. Показано, что модель, обученная на смешанном датасете, содержащем различные алгоритмы встраивания, приобретает высокую обобщающую способность и обнаруживает стеговставки с высокой точностью, в то время как модель, обученная на одном адаптивном методе, оказывается узкоспециализированной. Полученные результаты подтверждают применимость нейросетевого стегоанализа для задач кибербезопасности, связанных с выявлением скрытого вредоносного контента.

Библиографический список

1. Bas, P. 'Break Our Steganographic System': The Ins and Outs of Organizing BOSS / P. Bas, T. Filler, T. Pevny // Proceedings of 13th International Conference on Information Hiding (IH'2011). – Prague, Czech Republic, May 2011. – Vol. 6958 (Lecture Notes in Computer Science). – P. 59–70.

2. Glorot, X. Understanding the difficulty of training deep feedforward neural networks / X. Glorot, Y. Bengio // Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics (AISTATS'2010). – Chia Laguna Resort, Sardinia, Italy, May 2010. – Vol. 9 (Proceedings of Machine Learning Research). – P. 249–256.

3. Yedroudj, M. Yedrouj-Net: An Efficient CNN for Spatial Steganalysis / M. Yedroudj, F. Comby, M. Chaumont // Proceedings of IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP'2018). – Calgary, Alberta, Canada, April 2018. – P. 2092–2096.